# Prédiction du Churn Client

## Telco Customer Churn

Mini-Projet — Systèmes Intelligents

Bachelor / Master Informatique

---


**Étudiants :**

Étudiant 1 — Khalid Harrat
Étudiant 2 — Ali Garmat

**Enseignant :**

Tarek AIT BAHA


**Date :** Avril 2026


Université Ibn Zohr — Département Informatique

# Table des matières

**1 Introduction et Contexte** **2**
1.1 Problématique . . . 2
1.2 Approche . . . 2

**2 Description du Dataset** **2**
2.1 Source et caractéristiques . . . 2
2.2 Distribution de la variable cible . . . 3

**3 Exploration des Données** **3**
3.1 Variables numériques . . . 3
3.2 Variables catégorielles . . . 4
3.3 Corrélations . . . 5

**4 Prétraitement des Données** **5**
4.1 Nettoyage . . . 5
4.2 Feature Engineering . . . 5
4.3 Encodage . . . 5
4.4 Normalisation et Split . . . 6

**5 Modélisation Supervisée** **6**
5.1 Modèles entraînés . . . 6
5.2 Résultats . . . 6
5.3 Matrices de confusion . . . 7
5.4 Courbes ROC . . . 7
5.5 Importance des features . . . 8

**6 Analyse Non Supervisée** **8**
6.1 K-Means Clustering . . . 8
6.2 Visualisation PCA . . . 9

**7 Interface Streamlit** **9**

**8 Conclusion** **9**
8.1 Résultats principaux . . . 9
8.2 Limites . . . 10
8.3 Pistes d'amélioration . . . 10

# Introduction et Contexte

Le **churn client** (attrition) désigne le phénomène par lequel un client cesse d'utiliser les services d'une entreprise. Dans le secteur des télécommunications, la rétention des clients est un enjeu majeur car acquérir un nouveau client coûte en moyenne 5 à 7 fois plus cher que de conserver un client existant.

## Problématique

L'objectif de ce projet est de concevoir un **système intelligent de prédiction du churn** capable de :

- Identifier les clients à risque de résiliation avant qu'ils ne partent
- Comprendre les facteurs qui influencent le churn
- Segmenter la clientèle pour des actions ciblées
- Fournir une interface utilisateur pour la prédiction en temps réel

## Approche

Notre pipeline de bout en bout suit les étapes suivantes :

1. Exploration des données (EDA)
2. Prétraitement et feature engineering
3. Modélisation supervisée (5 modèles comparés)
4. Analyse non supervisée (K-Means + PCA)
5. Interface Streamlit pour la prédiction

# Description du Dataset

## Source et caractéristiques

Nous utilisons le dataset **Telco Customer Churn** disponible sur Kaggle [1], publié par IBM. Il contient les données de 7 043 clients d'un opérateur télécom avec 21 variables.

Table 1 – Description des principales variables du dataset

| Variable | Type | Description |
|---|---|---|
| customerID | Identifiant | ID unique du client |
| gender | Catégorielle | Male / Female |
| SeniorCitizen | Binaire | 0 ou 1 |
| tenure | Numérique | Ancienneté en mois (0–72) |
| Contract | Catégorielle | Month-to-month, 1 an, 2 ans |
| MonthlyCharges | Numérique | Facture mensuelle (18–120$) |
| TotalCharges | Numérique | Total facturé |
| InternetService | Catégorielle | DSL, Fiber optic, No |
| **Churn** | **Binaire** | **Yes / No (variable cible)** |

1. https://www.kaggle.com/datasets/blastchar/telco-customer-churn

## Distribution de la variable cible

Le dataset est **déséquilibré** : 73,5% des clients ne churnent pas (No) contre 26,5% qui churnent (Yes), soit environ 1 869 clients sur 7 043.

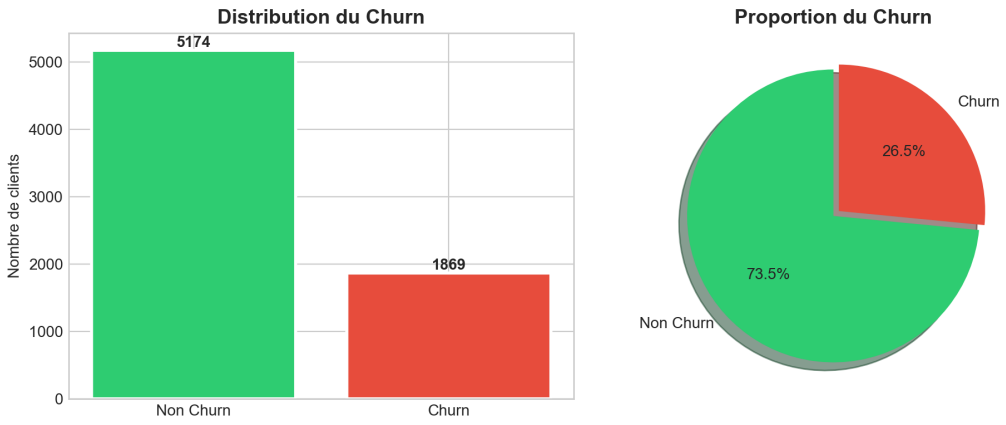


FIGURE 1 – Distribution de la variable cible (Churn)

# Exploration des Données

## Variables numériques

L'analyse des distributions révèle des tendances importantes :

- **Tenure** : les clients qui churnent ont tendance à avoir une faible ancienneté
- **MonthlyCharges** : les charges mensuelles élevées sont corrélées au churn
- **TotalCharges** : logiquement lié à la tenure, les clients récents ont des totaux bas

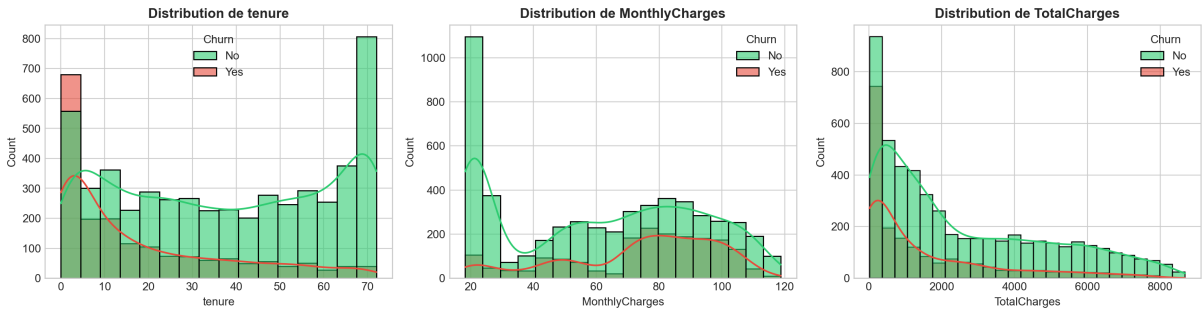


FIGURE 2 – Distribution des variables numériques par statut de churn

## Variables catégorielles

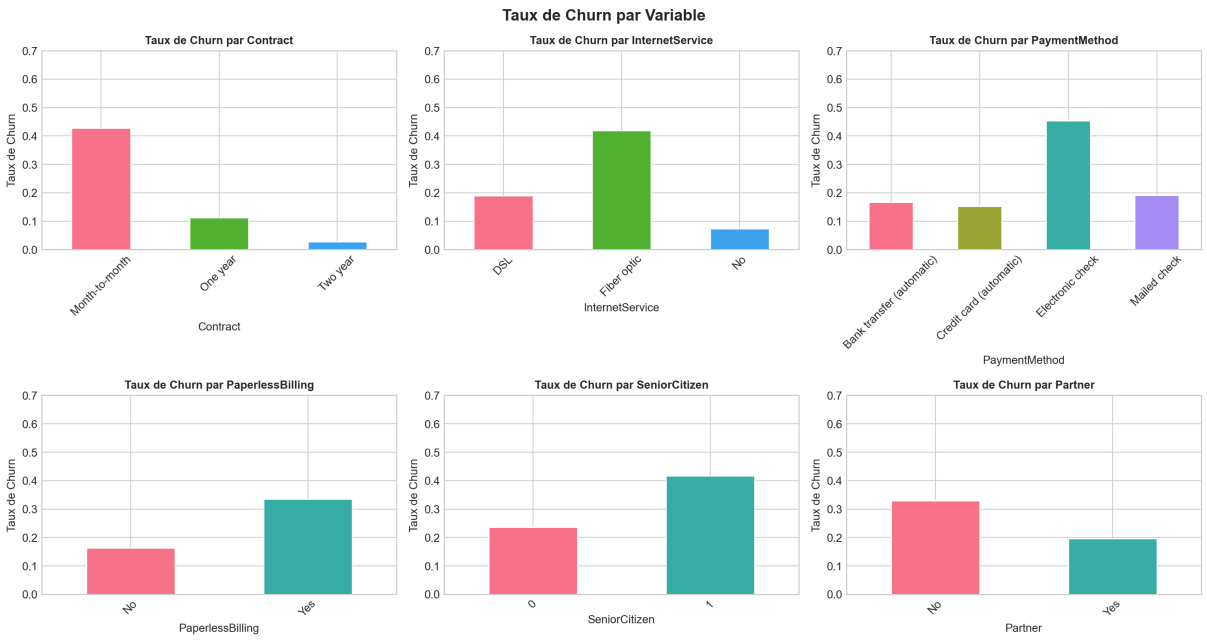


FIGURE 3 – Taux de churn par variable catégorielle

**Observations clés :**

- Le contrat *Month-to-month* a un taux de churn ≈43%, contre ≈11% pour un contrat de 2 ans
- Les clients avec *Fiber optic* churnent significativement plus (≈42%)
- Le paiement par *Electronic check* est associé à un churn élevé (≈45%)

## Corrélations

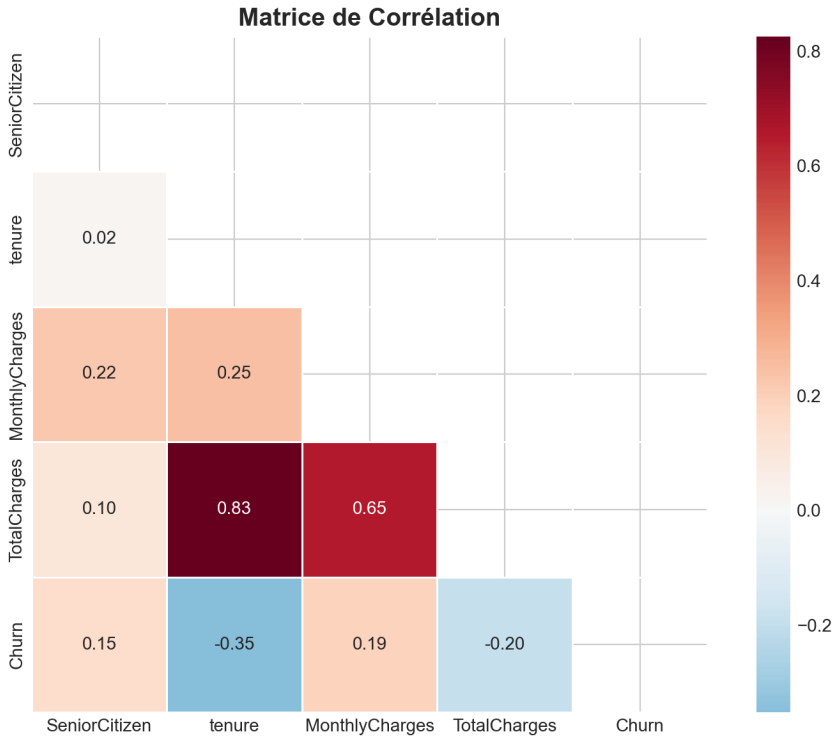


FIGURE 4 – Matrice de corrélation des variables numériques

La corrélation entre `tenure` et `TotalCharges` est forte (0.83), ce qui est logique. La variable `MonthlyCharges` est modérément corrélée au churn.

# Prétraitement des Données

## Nettoyage

- **TotalCharges** : 11 valeurs vides (espaces) correspondant à des clients avec tenure=0 → remplacées par la médiane
- **customerID** : supprimé car non pertinent pour la modélisation

## Feature Engineering

Deux nouvelles features ont été créées :

- **ChargesPerTenure** = MonthlyCharges / (tenure + 1) : ratio de charges par mois d'ancienneté
- **IsNewCustomer** = 1 si tenure $\leq$ 6 mois : indicateur de nouveau client

## Encodage

- **Variables binaires** (gender, Partner, etc.) : Label Encoding (0/1)
- **Variables multi-catégories** (Contract, InternetService, etc.) : One-Hot Encoding avec `drop_first=True`

### Normalisation et Split

— **StandardScaler** appliqué sur toutes les features (moyenne=0, écart-type=1)
— **Split** : 80% train / 20% test avec **stratification** sur la variable cible

## Modélisation Supervisée

### Modèles entraînés

Cinq modèles de classification ont été entraînés et comparés :

1. **Régression Logistique** : modèle linéaire de référence
2. **Random Forest** : ensemble d'arbres de décision (100 arbres)
3. **SVM** : séparateur à vaste marge (noyau RBF)
4. **k-NN** : k plus proches voisins (k=5)
5. **Arbre de Décision** : arbre simple (profondeur max=10)

### Résultats

Table 2 – Comparaison des performances des 5 modèles

| Modèle | Accuracy | Precision | Recall | F1-Score | AUC |
|---|---|---|---|---|---|
| **Logistic Regression** | **0.8034** | **0.6678** | 0.5160 | **0.5822** | **0.8465** |
| Random Forest | 0.7857 | 0.6277 | 0.4733 | 0.5396 | 0.8228 |
| SVM | 0.8027 | 0.6690 | 0.5080 | 0.5775 | 0.7980 |
| k-NN | 0.7715 | 0.5743 | 0.5374 | 0.5552 | 0.7769 |
| Decision Tree | 0.7537 | 0.5354 | 0.5455 | 0.5404 | 0.7174 |

**Meilleur modèle :** La **Régression Logistique** obtient le meilleur F1-Score (0.5822) et la meilleure AUC (0.8465), ce qui en fait le modèle le plus équilibré entre précision et rappel.

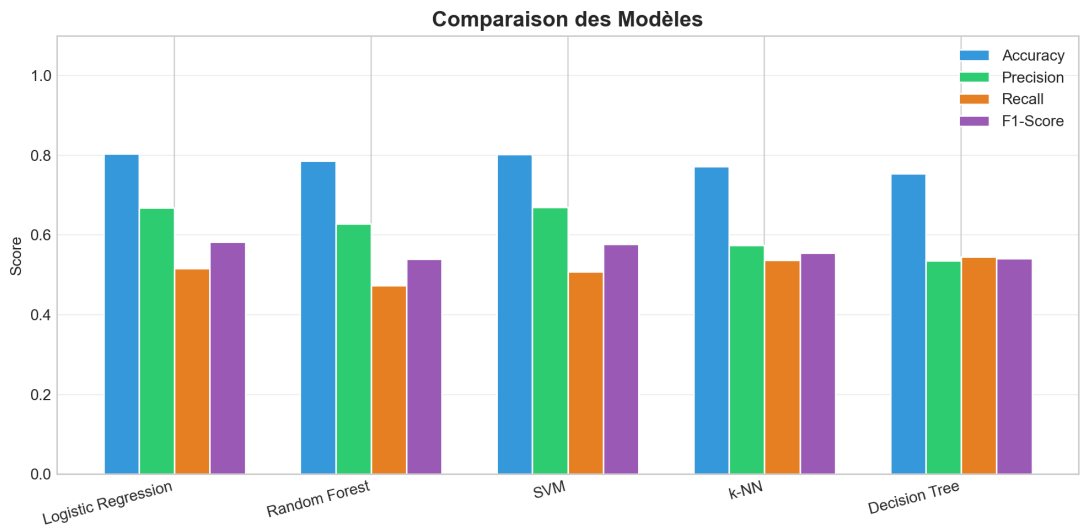


Figure 5 – Comparaison visuelle des métriques par modèle

## Matrices de confusion

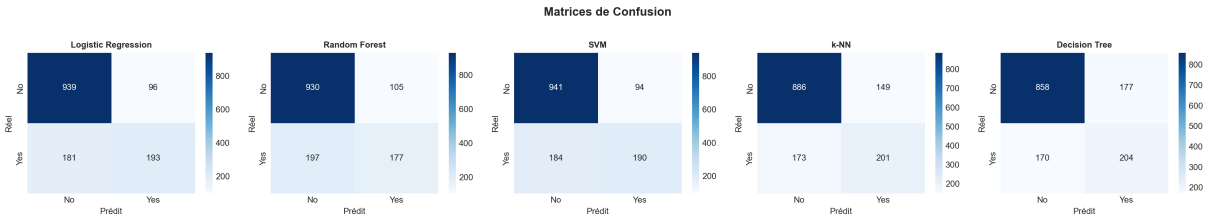


FIGURE 6 – Matrices de confusion des 5 modèles

## Courbes ROC

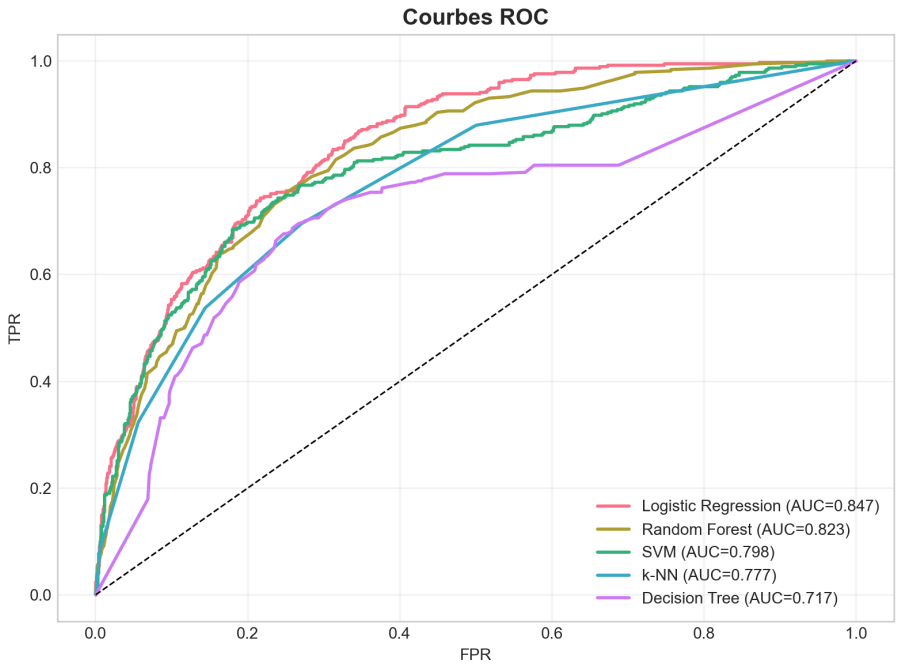


FIGURE 7 – Courbes ROC — Comparaison des modèles

La Régression Logistique domine avec une AUC de 0.847, suivie par le Random Forest (0.823).

### Importance des features

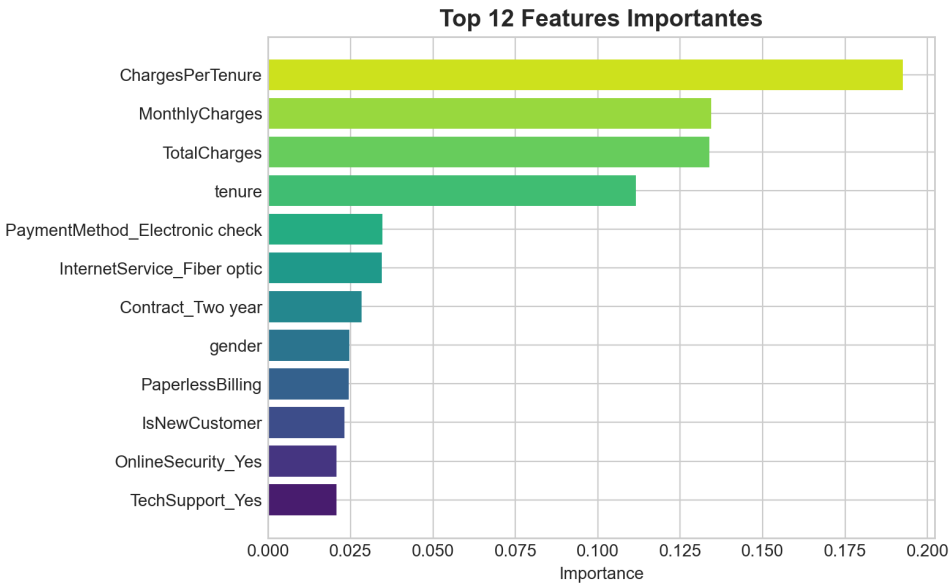


FIGURE 8 – Top 12 features les plus importantes (Random Forest)

Les features les plus discriminantes sont : `TotalCharges`, `MonthlyCharges`, `tenure` et `ChargesPerTenure` (notre feature engineerée).

## Analyse Non Supervisée

### K-Means Clustering

La méthode du coude et le score de silhouette ont été utilisés pour déterminer le nombre optimal de clusters.

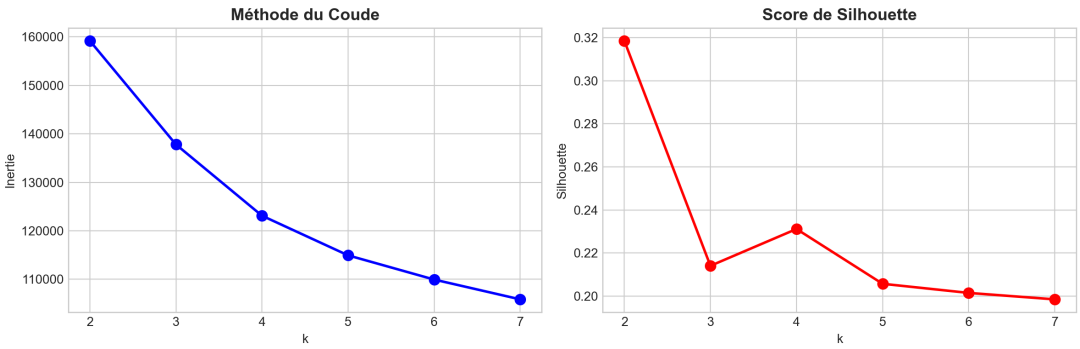


FIGURE 9 – Méthode du coude et score de silhouette

Nous avons retenu **k=3 clusters**, identifiant trois segments de clientèle avec des profils et des taux de churn distincts.

## Visualisation PCA

La PCA (Analyse en Composantes Principales) permet de projeter les données en 2D pour visualiser les clusters et le churn.

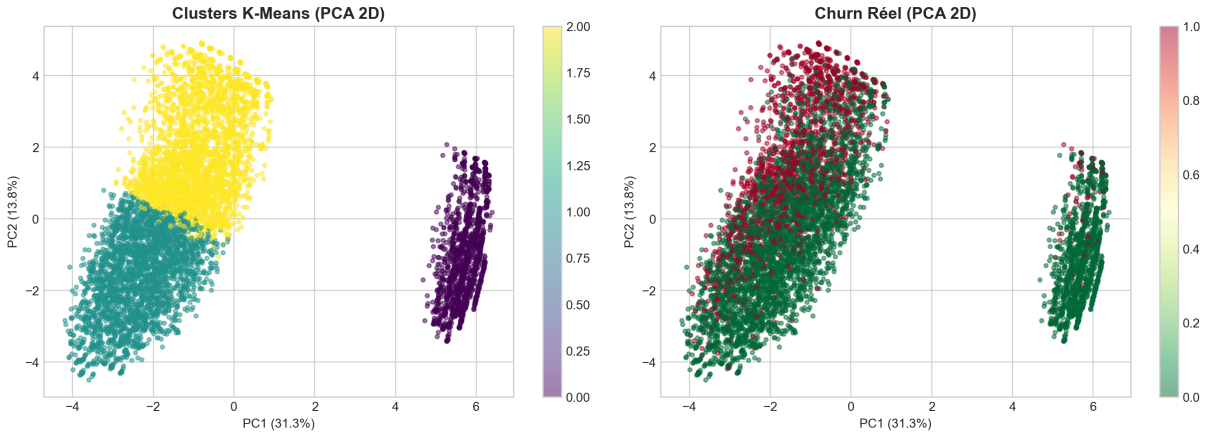


FIGURE 10 – Projection PCA 2D : clusters K-Means (gauche) vs churn réel (droite)

**Interprétation :** Les 3 segments montrent des taux de churn différenciés, ce qui confirme que la segmentation peut aider à cibler les actions de rétention par groupe de clients.

# Interface Streamlit

Une application web interactive a été développée avec **Streamlit** pour permettre la prédiction du churn en temps réel :

- **Sidebar** : formulaire de saisie des caractéristiques du client (démographie, contrat, services, charges)
- **Récapitulatif** : tableau synthétique des informations saisies
- **Prédiction** : probabilité de churn avec indicateur visuel (vert/rouge)
- **Recommandations** : actions suggérées en cas de risque de churn

L'application est lancée avec la commande :

```
streamlit run app/streamlit_app.py
```

# Conclusion

## Résultats principaux

- 5 modèles de classification entraînés et comparés
- La **Régression Logistique** est le meilleur modèle (F1=0.58, AUC=0.85)
- 3 segments de clients identifiés par K-Means avec des taux de churn distincts
- Interface Streamlit opérationnelle pour la prédiction en temps réel

## Limites

- Le dataset est **déséquilibré** (73% vs 27%), ce qui pénalise le rappel
- Les **hyperparamètres** n'ont pas été optimisés (pas de GridSearch/RandomSearch)
- Les features sont limitées à celles disponibles dans le dataset
- Le recall reste modeste (≈0.52), ce qui signifie que le modèle manque environ la moitié des clients qui vont churner

## Pistes d'amélioration

- **SMOTE** (Synthetic Minority Over-sampling Technique) pour rééquilibrer les classes
- **GridSearchCV** pour optimiser les hyperparamètres de chaque modèle
- **Modèles avancés** : XGBoost, LightGBM, réseaux de neurones
- **Features temporelles** : évolution des charges au fil du temps
- **Déploiement cloud** : Docker + hébergement (Heroku, AWS, etc.)